

Raport Proiect: Predicția Prețurilor Locuințelor (Housing Prices Competition for Kaggle Learn Users)

1. Obiectivul Proiectului

Dezvoltarea unui model de învățare automată (Machine Learning) capabil să estimeze prețul de vânzare al locuințelor folosind setul de date 'Housing Prices Competition for Kaggle Learn Users'. Proiectul s-a concentrat pe optimizarea preciziei prin tehnici de preprocesare și inginerie a datelor.

2. Analiza Exploratorie a Datelor (EDA) și Curățarea Datelor

- **Analiza Corelațiilor:** Am calculat coeficienții de corelație între variabilele numerice și variabila țintă (*SalePrice*).
- **Vizualizare Datelor:** Am generat grafice de tip *Scatter Plot* pentru variabilele cu corelație ridicată (> 0.6), precum colanele *GrLivArea* și *OverallQual*.
- **Tratarea Outlierilor:** În urma vizualizării, am identificat anomalii statistice (outlieri) — în special case cu suprafețe foarte mari vândute la prețuri neobișnuit de mici. Eliminarea acestora a fost necesară pentru a preveni distorsionarea modelului.

3. Preprocesarea Datelor și Arhitectura Pipeline-ului

Pentru a asigura un flux de lucru eficient și a evita scurgerea datelor (*data leakage*), am construit un **Pipeline** care a inclus:

- **Imputarea Datelor:** Gestionarea valorilor lipsă pentru variabilele numerice și categoricale.
- **Encoding (Codificare):**
 - *One-Hot Encoding* pentru variabilele nominale (fără ordine intrinsecă).
 - *Ordinal Encoding* pentru variabilele care prezintă o ierarhie de calitate (ex: Poor, Average, Good, Excellent).
- **Separarea Datelor:** Împărțirea setului în sub-seturi de antrenament (*Train*) și validare (*Validation*).

4. Feature Engineering

Aceasta a fost etapa care a adus cea mai mare îmbunătățire a scorului:

- **Crearea de variabile noi:** Am sintetizat variabile, cum ar fi '**TotalSF**' (suprafața totală a casei), combinând suprafețele subsolului și ale etajelor.
- **Feature Selection:** Am utilizat tehnici de selecție a caracteristicilor pentru a păstra doar variabilele cu o importanță mai mare de 0.001, eliminând „zgomotul” cauzat de coloanele cu impact redus.

5. Optimizare avansată a modelelor (Meta-euristici)

Pentru a depăși limitele optimizării clasice, am introdus o etapă de tuning avansat:

- **Algoritmi Genetici (PyGAD):** Am utilizat algoritmi genetici pentru a optimiza hiperparametrii modelului XGBoost. Această abordare meta-euristică a permis explorarea unui spațiu de căutare complex, găsind o combinație de parametri (learning rate, max_depth, n_estimators) superioară tehnicilor standard de tip GridSearch.

6. Implementare și interfață interactivă

Proiectul a fost transformat dintr-un model static într-o aplicație web funcțională:

- **Framework-ul Streamlit:** Am dezvoltat o interfață interactivă care permite utilizatorului să introducă caracteristicile unei case (suprafață, calitate, numărul camerelor) și să primească o estimare de preț.
- **Persistența Modelului:** Pipeline-ul de preprocesare și modelul optimizat au fost serializate folosind joblib, asigurând consistența între faza de antrenare și cea de predicție.

7. Containerizare (Integrare DevOps)

Pentru a asigura portabilitatea și stabilitatea sistemului:

- **Dockerizare:** Aplicația a fost împachetată într-un container Docker utilizând o imagine de bază python:3.11-slim.
- **Standardizarea mediului:** Prin utilizarea unui Dockerfile și a unui fișier requirements.txt, am eliminat problema "it works on my machine", permițând rularea aplicației pe orice server cu o singură comandă.
- **Optimizare:** Imaginea a fost optimizată pentru dimensiune și viteză, instalând doar dependențele esențiale pentru execuție.

8. Rezultate finale și concluzii

- **Performanță:** Modelul final bazat pe **XGBoost optimizat genetic** a demonstrat o capacitate ridicată de generalizare (GridSearch-> MAE $\approx$ 16.500, AG-> MAE $\approx$ 14.800).
- **Soluție end-to-end:** Proiectul acoperă întregul ciclu de creare al unui produs de AI: de la analiza exploratorie și curățarea datelor, la ingineria caracteristicilor, optimizarea matematică și livrarea către utilizatorul final printr-o infrastructură de tip container.
- **Direcții viitoare de dezvoltare:** Integrarea unei baze de date pentru stocarea predicțiilor și implementarea unui sistem de monitorizare a prețurilor în timp pentru a detecta momentul în care modelul are nevoie de re-antrenare.